

OneBox Agent

Reporte de Evaluación del Sistema IA

Para Stakeholders · 09 de June de 2026

6

Sesiones probadas

27

Turnos totales

14

Herramientas evaluadas

8.6/10

Satisfacción promedio

Este reporte documenta los resultados de las pruebas funcionales del agente conversacional OneBox, evaluando su capacidad para gestionar correos, proyectos, tareas, notificaciones y flujos integrados multi-paso.

Resumen Ejecutivo

El agente OneBox fue sometido a **6 sesiones de prueba con 27 turnos totales**, cubriendo todos los módulos funcionales del sistema. Los resultados muestran un sistema con **alto nivel de confiabilidad en el 100% de los flujos probados**. El agente completó todas las tareas solicitadas, respetó las validaciones de datos y nunca ejecutó acciones sin los parámetros necesarios.

Scorecard Global

#	Sesion	Turnos	Herramientas	Iter >1	Errores	Satisfacción
1	Gestión de Correo	6	listar_correos, inspeccionar_correo, analizar_inbox...	2	0	7.2/10
2	Gestión de Proyectos	6	crear_proyecto, crear_tarea, listar_proyectos...	1	0	7.8/10
3	Notificaciones	4	listar_proyectos, obtener_contactos_proyecto, enviar_notificacion	0	0	9.5/10
4	Herramientas Utilitarias	4	crear_recordatorio, verificar_sla, resumen_proactivo...	0	0	9.4/10
5	Flujo de Integración	3	crear_proyecto, listar_correos, asignar_correo_a_proyecto...	1	0	8.1/10
6	Validación Fix (Cache)	4	crear_proyecto, crear_tarea, analizar_inbox...	0	0	9.8/10
PROMEDIO		27		4	0	8.6/10

Fortalezas Confirmadas

- ✓ Las reglas de validación funcionan: el agente nunca ejecuta acciones con datos incompletos.
- ✓ El flujo de notificaciones masivas (foreach) opera en 1 iteracion sin errores.
- ✓ La inferencia de tipo de proyecto y fases desde texto libre es una capacidad diferencial.
- ✓ El agente toma datos de contexto de conversacion sin pedirlos nuevamente al usuario.
- ✓ La distincion entre herramientas similares (verificar_sla vs resumen_proactivo) es correcta.

Mejoras Identificadas

- Agregar ejemplo explicito para patron 'from:' en remitentes conocidos (catalog.py).
- Mejorar coherencia del narrador en clasificar_mensajes_automatico tras analizar_inbox.
- Probar crear_insight (unica herramienta sin cobertura) en el proximo ciclo.

Sesion 1 - Gestión de Correo

7.2/10

6

Turnos

2

Iter. >1

0

Errores

Bueno

Estado

Herramientas: [listar_correos](#) · [inspeccionar_correo](#) · [analizar_inbox](#) · [clasificar_mensajes_automatico](#) · [enviar_correo](#)

Que resolvió el agente

El agente localizó correos por remitente, inspeccionó el contenido de un correo específico, analizó el inbox completo y clasificó mensajes automáticamente. Redactó y envió un correo tomando el destinatario del contexto de la conversación sin pedirlo al usuario.

Problemas / Observaciones

En 2 turnos el planner necesitó 2 iteraciones: usó query genérica en lugar del prefijo 'from:' para filtrar por remitente conocido. Se corrigió solo en la segunda iteración.

Conclusion: Flujo de correo sólido. El único punto de mejora es agregar un ejemplo explícito en las reglas del planner para usar 'from:' directamente con remitentes conocidos, eliminando la iteración extra.

Envío con contexto ✓

Análisis de inbox ✓

Clasificación automática ✓

Sesion 2 - Gestión de Proyectos

7.8/10

6

Turnos

1

Iter. >1

0

Errores

Bueno

Estado

Herramientas: [crear_proyecto](#) · [crear_tarea](#) · [listar_proyectos](#) · [asignar_correo_a_proyecto](#)

Que resolvió el agente

Creó un proyecto completo ('Alpha') extrayendo fases y participantes de una descripción libre. Generó tareas automáticamente. Listó proyectos existentes. La asignación de correos a proyectos funcionó correctamente una vez resuelto el bug de cache en modo debug.

Problemas / Observaciones

En modo de prueba (dry-run), `listar_proyectos` no retornaba proyectos recién creados, causando que el match por nombre fallara en flujos multi-turno. Bug de infraestructura de pruebas — corregido.

Conclusion: El razonamiento del planner para proyectos es una de las mayores fortalezas del sistema. La extracción de fases desde descripciones no estructuradas funcionó correctamente. Bug de dry-run resuelto en este ciclo.

Extracción de fases ✓

Tareas automáticas ✓

Bug dry-run corregido ✓

Sesion 3 - Notificaciones

9.5/10

4

Turnos

0

Iter. >1

0

Errores

Perfecto

Estado

Herramientas: [listar_proyectos](#) · [obtener_contactos_proyecto](#) · [enviar_notificacion](#)

Que resolvió el agente

Envío notificaciones WhatsApp a múltiples contactos de un proyecto en un solo paso usando 'foreach'. También envió notificaciones individuales con número directo. Gestionó correctamente los casos de contactos sin teléfono registrado.

Problemas / Observaciones

Ninguno detectado.

Conclusion: El flujo de notificaciones masivas es el más robusto del sistema. El patrón multi-paso funciona perfectamente en una sola iteración, sin errores de resolución de parámetros.

Foreach multi-destinatario ✓

Manejo sin teléfono ✓

1 iteración siempre ✓

Sesion 4 - Herramientas Utilitarias

9.4/10

4

Turnos

0

Iter. >1

0

Errores

Perfecto

Estado

Herramientas: [crear_recordatorio](#) · [verificar_sla](#) · [resumen_proactivo](#) · [crear_tarea](#)

Que resolvió el agente

Creó recordatorios con y sin datos completos. Distinguió correctamente entre `verificar_sla` (alertas urgentes) y `resumen_proactivo` (estado general). Rechazó crear una tarea sin proyecto con una respuesta directa apropiada.

Problemas / Observaciones

Ninguno detectado.

Conclusion: Las herramientas utilitarias muestran madurez en las reglas de validación. El agente no ejecuta acciones sin los datos necesarios, protegiendo la integridad de los datos y la experiencia del usuario.

Validación previa ✓

Distinción SLA vs proactivo ✓

Protección sin proyecto ✓

Sesion 5 - Flujo de Integración

8.1/10

3

Turnos

1

Iter. >1

0

Errores

Bueno

Estado

Herramientas: [crear_proyecto](#) · [listar_correos](#) · [asignar_correo_a_proyecto](#) · [enviar_notificacion](#)

Que resolvió el agente

Ejecutó un flujo end-to-end: creó un proyecto de Marketing con fases inferidas desde el nombre ('campaña de verano'), buscó correos relacionados y los asignó al proyecto, y envió notificaciones al equipo de forma masiva.

Problemas / Observaciones

El flujo de asignación requirió 3 iteraciones en el planner por la limitación de dry-run (mismo bug que Sesión 2, ya corregido).

Conclusion: La integración entre módulos funciona. La inferencia de tipo de proyecto y la generación automática de fases sectoriales son capacidades diferenciales del agente.

Inferencia de tipo ✓

Flujo end-to-end ✓

Notificación integrada ✓

Sesion 6 - Validación Fix (Cache)

9.8/10

4

Turnos

0

Iter. >1

0

Errores

Perfecto

Estado

Herramientas: [crear_proyecto](#) · [crear_tarea](#) · [analizar_inbox](#) · [listar_proyectos](#) · [asignar_correo_a_proyecto](#)

Que resolvió el agente

Flujo de regresión post-fix: creó proyecto 'Alpha', luego en un turno posterior buscó correos y los asignó al proyecto por nombre. Por primera vez `listar_proyectos` devolvió 'Alpha' correctamente, confirmando que el cache in-memory funciona.

Problemas / Observaciones

Ninguno. El fix resolvió el bug de manera completa.

Conclusion: La corrección del bug de persistencia en modo debug está verificada. El flujo multi-turno `crear-proyecto → asignar-correo` ahora funciona en 1 iteración, reflejando el comportamiento esperado en producción.

Bug corregido ✓

1 iter en asignación ✓

Cache in-memory ✓

Proximos Pasos y Recomendaciones

Prioridad Media	Agregar ejemplo explicito para patron 'from:' con remitentes conocidos	<i>catalog.py - SEARCH_GUIDE</i>	Elimina iteracion extra en busquedas por remitente
Prioridad Media	Mejorar coherencia del narrador en clasificar_mensajes_automatico	<i>narrator/narrators/</i>	Evita contradicciones con el turno anterior
Prioridad Baja	Probar herramienta crear_insight (unica sin cobertura)	<i>Proximo ciclo de pruebas</i>	Completar cobertura al 100%

El agente OneBox obtuvo una **satisfaccion promedio de 8.6/10** en las pruebas funcionales. Todos los flujos criticos de negocio fueron completados exitosamente. Las mejoras identificadas son de alcance acotado y no bloquean el uso en produccion. El sistema esta listo para su despliegue con los ajustes de prioridad media pendientes.